Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №4

По дисциплине: «Интеллектуальный анализ данных»
Тема: «Предобучение нейронных сетей с использованием RBM»

Выполнил:
Студент 4 курса
Группы ИИ-25
Трошин И.Д.
Проверила:
Андренко К.В.

Брест 2026

Цель работы: научиться осуществлять предобучение нейронных сетей с помощью RBM.

Общее задание

1. Взять за основу нейронную сеть из лабораторной работы №3. Выполнить обучение с предобучением, используя стек ограниченных машин Больцмана (RBM – Restricted Boltzmann Machine), алгоритм которого изложен в лекции. Условие останова (например, по количеству эпох) при обучении отдельных слоев как RBM выбрать самостоятельно.

2. Сравнить результаты, полученные при
- обучении без предобучения (ЛР 3);
- обучении с предобучением, используя автоэнкодерный подход (ЛР3);
- обучении с предобучением, используя RBM.

3. Обучить модели на данных из ЛР 2, сравнить результаты по схеме из пункта 2;

4. Сделать выводы, оформить отчет по выполненной работе, загрузить исходный код и отчет в соответствующий репозиторий на github.

Вариант 13

№	Выборка	Тип задачи	Целевая переменная
13	https://archive.ics.uci.edu/dataset/863/maternal+health+risk	классификация	RiskLevel

Ход работы

Исходный файл имеет структуру:

Age	SystolicBP	DiastolicBP	BS	BodyTemp	HeartRate	RiskLevel
25	130	80	15	98	86	high risk
35	140	90	13	98	70	high risk
29	90	70	8	100	80	high risk
30	140	85	7	98	70	high risk

Подготовка данных

Выборка делится на обучающую и тестовую в пропорции 80/20. Признаки масштабируются в диапазон [0, 1] (MinMaxScaler, параметры подбираются по обучающей выборке). Такой диапазон соответствует области значений сигмоиды, которая используется на выходе автоэнкодера.

Maternal Health Risk. Шесть признаков (Age, SystolicBP, DiastolicBP, BS, BodyTemp, HeartRate), три класса: low risk, mid risk, high risk. В исходных данных 1014 записей, из них 562 дубликата. Дубликаты удалены, чтобы одинаковые объекты не попадали

одновременно в обучающую и тестовую выборки. Осталось 452 объекта: 234 low risk, 106 mid risk, 112 high risk.

Rice. 3810 объектов, семь морфологических признаков (Area, Perimeter, Major_Axis_Length, Minor_Axis_Length, Eccentricity, Convex_Area, Extent), два класса: Cammeo (1630) и Osmancik (2180). Дубликатов нет.

Для обеих выборок: разбиение на обучающую и тестовую части 80/20 со стратификацией (random_state = 0), признаки приведены к диапазону [0, 1] (MinMaxScaler, параметры подбираются по обучающей выборке). Такой диапазон нужен сигмоидным нейронам и бинарным нейронам RBM. Размер тестовой выборки: 91 объект для Maternal Health Risk и 762 объекта для Rice.

Архитектура сети

Полносвязная сеть: вход, три скрытых слоя по 32, 32 и 16 нейронов с сигмоидной активацией, выходной слой по числу классов (3 и 2 соответственно). Всего четыре слоя весов. Для Maternal Health Risk это 6-32-32-16-3, для Rice 7-32-32-16-2.

Выход нейрона: $y = f(s)$, где $s = \Sigma\, w_i x_i - T$, а T порог нейрона. Функция потерь при обучении классификатора: Cross Entropy. Скрытые слои имеют сигмоидную активацию, на выходе логиты, а softmax входит в CE.

Три варианта обучения

1. Без предобучения. Сеть обучается целиком 200 эпох.
2. Автоэнкодерное предобучение (ЛР 3). Каждый слой предобучается автоэнкодером с MSE (100 эпох), затем 50 эпох обучается только выходной слой и 200 эпох вся сеть.
3. Предобучение RBM. Скрытые слои предобучаются RBM (100 эпох на слой), затем те же 50 эпох только выходной слой и 200 эпох вся сеть.

Параметры экспериментов

Параметр	Значение
Оптимизатор (обучение с учителем и автоэнкодер)	SGD, момент 0,9
Скорость обучения (обучение с учителем и автоэнкодер)	0,1
Скорость обучения RBM	0,05
Момент RBM	0,5 на первых 5 эпохах, затем 0,9
Размер мини-батча	32
Эпох предобучения одного слоя	100
Эпох обучения только выходного слоя	50
Эпох обучения всей сети	200

Параметр	Значение
Инициализация весов	Xavier (RBM: 0,1·N(0, 1))

Метрики

- **Accuracy** — доля правильно классифицированных объектов.
- **Macro-F1** — среднее F1-мер по классам без учёта их размера. Метрика штрафует за пренебрежение редкими классами, в отличие от accuracy.
- **Матрица ошибок (confusion matrix)** — таблица, где строки соответствуют истинному классу, а столбцы предсказанному. Диагональ содержит верные ответы, остальные ячейки показывают, какие классы модель путает.

Результат

Maternal Health Risk

Модель	Accuracy	Macro-F1
Без предобучения	0,670	0,491
Автоэнкодер	0,659	0,537
RBM	**0,703**	**0,585**

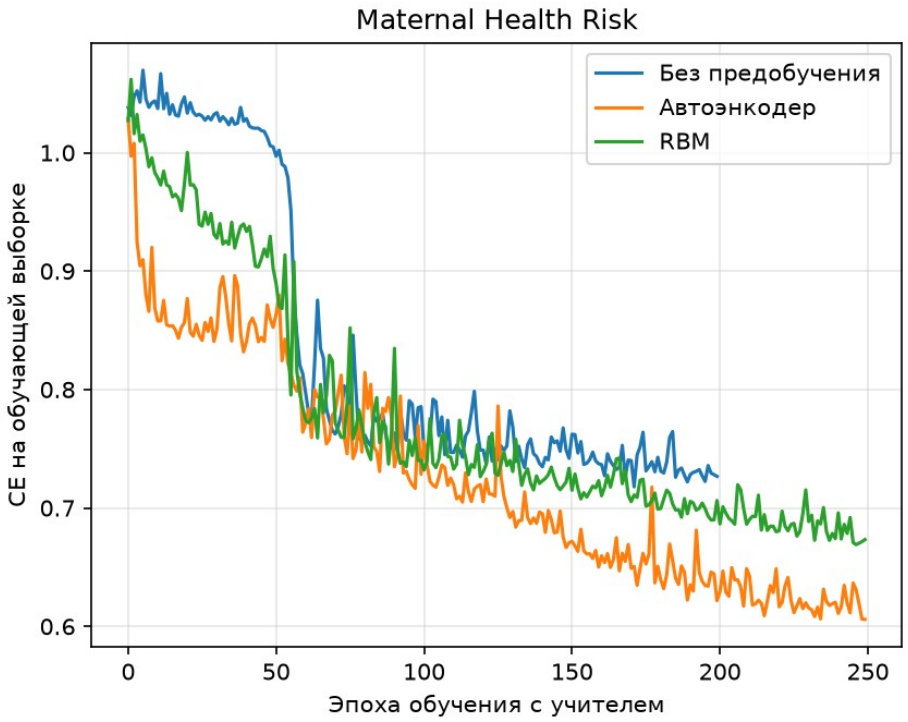
Матрицы ошибок:

Без предобучения:

	low	mid	high
low	44	0	3
mid	14	0	7
high	6	0	17

Автоэнкодер:

	low	mid	high
low	41	2	4
mid	13	2	6
high	3	3	17



RBM:

	low	mid	high
low	43	0	4
mid	12	3	6
high	3	2	18

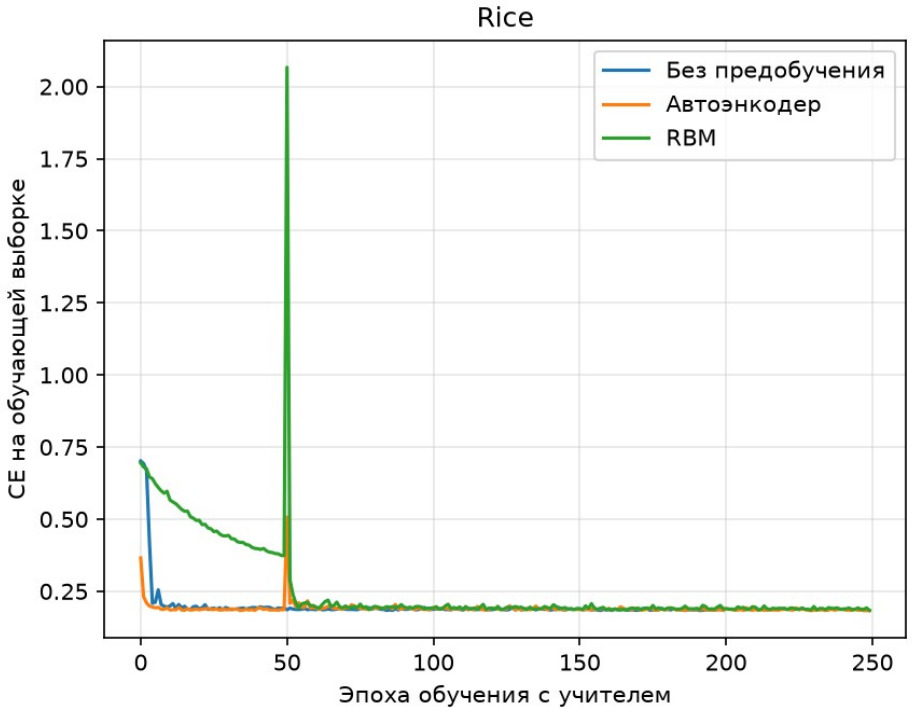
Rice

Модель	Accuracy	Macro-F1
Без предобучения	0,923	0,921
Автоэнкодер	0,923	0,922
RBM	0,919	0,916

Матрицы ошибок:

Без предобучения:

	Cammeo	Osmancik
Cammeo	305	21
Osmancik	38	398



Автоэнкодер:

	Cammeo	Osmancik
Cammeo	307	19
Osmancik	40	396

RBM:

	Cammeo	Osmancik
Cammeo	282	44
Osmancik	18	418

Maternal Health Risk. Лучший результат дало предобучение RBM: accuracy выросла с 0,670 до 0,703, macro-F1 с 0,491 до 0,585. Автоэнкодерное предобучение подняло macro-F1 до 0,537, но accuracy немного снизилась (0,659). Основное различие связано с классом mid risk. Сеть без предобучения не предсказала его ни разу, автоэнкодер нашел 2 объекта из 21, RBM нашел 3 из 21 с точностью 60% (3 из 5 предсказаний верны).

Вывод: реализовано предобучение нейронной сети стеком RBM по алгоритму CD-1 и выполнено сравнение трех способов обучения (без предобучения, автоэнкодер, RBM) на двух выборках.

1. На малой выборке Maternal Health Risk предобучение RBM дало лучший результат: accuracy 0,703 и macro-F1 0,585 против 0,670 и 0,491 без предобучения. Предобучение автоэнкодерами повысило macro-F1 до 0,537 при некотором снижении accuracy. Основной эффект обоих методов связан с распознаванием трудного промежуточного класса mid risk.

2. На большой выборке Rice с хорошо разделимыми признаками предобучение преимуществ не дало: все три варианта показали accuracy 0,919–0,923.

3. Предобучение эффективно для малых выборок, а при достаточном объеме данных и информативных признаках обычное обучение дает такое же качество.